OpenCV Python + Tesseract-OCR輕鬆實現中文識別

原創 陰沉魚 OpenCV學堂 昨天



微信公眾號: OpenCV學堂

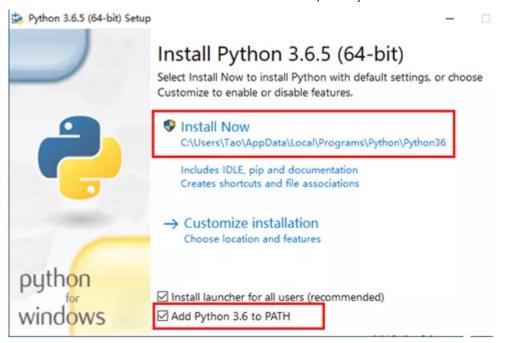
關注獲取更多計算機視覺與深度學習知識

01 軟件版本

- Python3.6.5
- OpenCV-Python 4.x
- Tesseract-OCR 5.0.0-alpha.20201127
- Win10 64

02 安裝與配置

安裝Python SDK選擇默認安裝,同時勾選最下面得紅色矩形框内容。



安裝opencv-python開發包

```
pip install opencv-python
```

安裝Tesseract-OCR Python SDK支持

```
1 pip install pytesseract
```

下載Tesseract-OCR 5.0.0-alpha.20201127安裝包並安裝! 然後在環境變量中添加

```
1 C:\Program Files\Tesseract-OCR
```

03 驗證與測試

安裝與配置好OpenCV-Python與Tesseract-OCR之後,需要進一步通過代碼驗證正確性。打開Pycharm IDE,新建一個python項目與python文件,輸入以下代碼

```
import pytesseract as tess
print(tess.get_tesseract_version())
print(tess.get_languages())
```

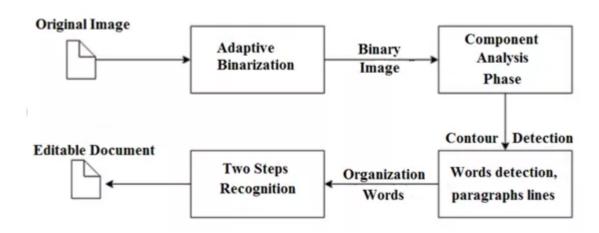
運行結果如下:

```
5.0.0-alpha.20201127 ['eng', 'osd']
```

第一行是版本信息,第二行是支持的語言信息,默認只支持英文。

Tesseract-OCR介紹

開源的OCR識別引擎, 高版本識別基於LSTM, 其整個處理流程如下:



檢測與識別文本函數:

檢測:

```
def image_to_boxes(
    image,
    image,
    lang=None,
    config='',
    nice=0,
    output_type=Output.STRING,
    timeout=0,
    )
```

返回所有識別文字的Box框坐標,每一行為一個BOX信息輸出 每行的前五個值分別是,識別的字符、BOX框的左上角與右下角坐標

識別

```
def image_to_string(
   image,
   lang=None,
   config='',
   nice=0,
   output_type=Output.STRING,
   timeout=0,
   )
```

輸入的圖像通道順序是RGB, OpenCV默認為BGR, 返回的是識別結果 必輸入的参数是image, 其它可选

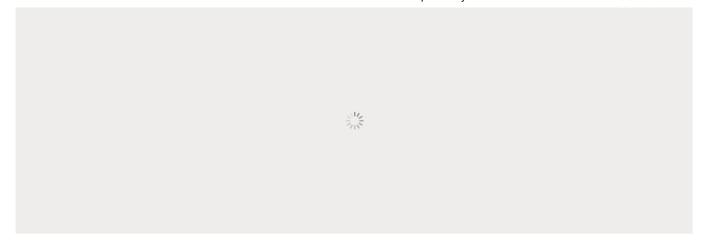
英文与数字识别

Tesseract-OCR默认支持英文与数字识别,有输入图像如下:

Python代码如下:

```
image = cv.imread("D:/cv4j.png")
image_rgb = cv.cvtColor(image, cv.COLOR_BGR2RGB)
text = tess.image_to_string(image_rgb, lang="eng")
content = text.replace("\f", "").split("\n")
for c in content:
    if len(c) > 0:
        print(c)
h, w, c = image.shape
boxes = tess.image_to_boxes(image)
for b in boxes.splitlines():
    b = b.split(' ')
    image = cv.rectangle(image, (int(b[1]), h - int(b[2])), (int(b[3]), h - int(b[4]))
cv.imshow('text detect', image)
cv.waitKey(0)
cv.destroyAllWindows()
```

运行结果如下:



英文识别对无干扰的背景效果非常好!

中文识别

默认情况下Tesseract-OCR不支持中文识别,需要下载中文识别的模型文件,然后放置到安装路径的tessdata目录下:

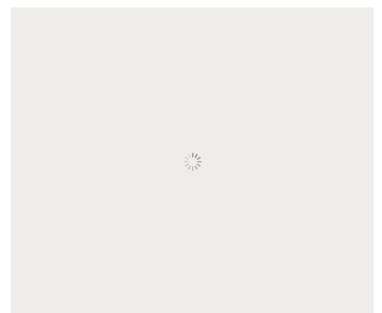
```
1 C:\Program Files\Tesseract-OCR\tessdata
```

然后在运行语言检查支持代码,运行结果如下:



其中chi_sim表示中文简体支持, eng表示英文支持!

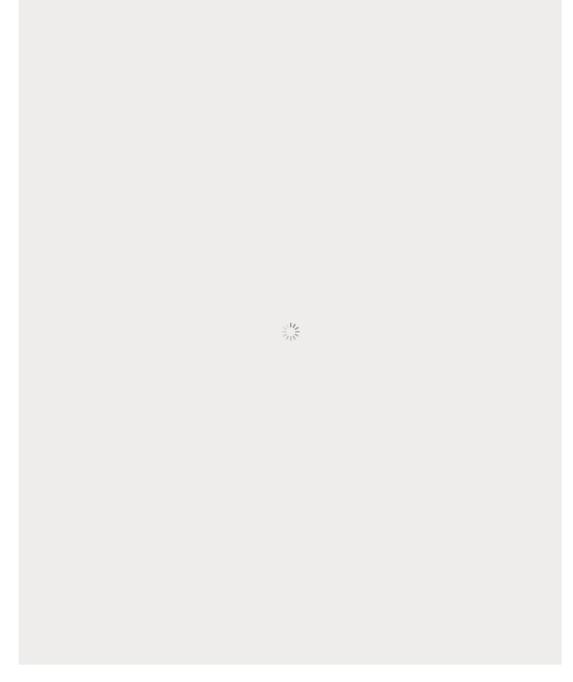
以下图为例:



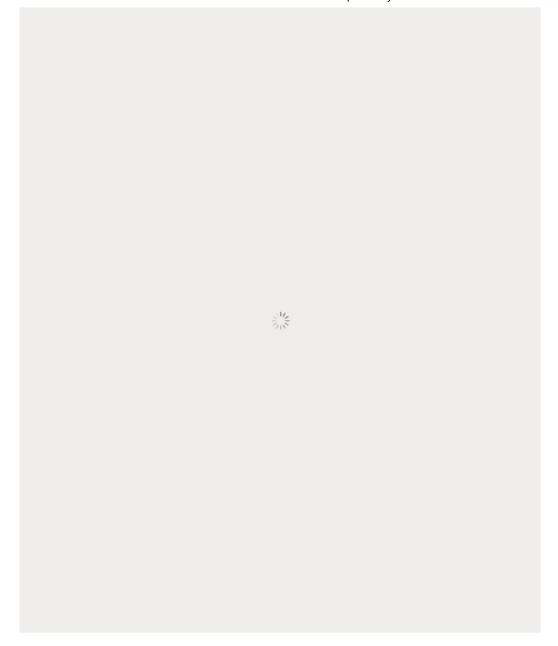
识别代码

```
image = cv.imread("D:/yanxishe.png")
image_rgb = cv.cvtColor(image, cv.COLOR_BGR2RGB)
text = tess.image_to_string(image_rgb, lang="chi_sim")
print(text)
h, w, c = image.shape
boxes = tess.image_to_boxes(image)
for b in boxes.splitlines():
    b = b.split(' ')
    image = cv.rectangle(image, (int(b[1]), h - int(b[2])), (int(b[3]), h - int(b[4]))
cv.imshow('text detect', image)
cv.waitKey(0)
cv.destroyAllWindows()
```

运行结果



正确率还不错,需要进一步处理一下,直接放大两倍,然后再测试一波



发现错误识别大大减少,基本可用!

总结一下:使用OpenCV预处理可以大大降低Tesserct-OCR的误识别率!



直接识别原图,发现图像上的灰度文字被忽视,无法识别!

君子藏器于身,待时而动

推荐阅读

OpenCV4系统化学习路线图-视频版本!

Tensorflow + OpenCV4 安全帽检测模型训练与推理

汇总 | OpenCV DNN模块中支持的分类网络

OpenCV中支持的人脸检测方法整理与汇总

从3D人脸到自动驾驶,CVPR2020十个顶级开源数据集

轻松学Pytorch - 构建UNet实现道路裂纹检测

详解ENet | CPU可以实时的道路分割网络

从Pytorch 的ONNX到OpenVINO中IR中间层

OpenVINO中的FCOS人脸检测模型代码演示

详解OpenVINO 模型库中的人脸检测模型

效果特好 | OpenVINO手写数字识别

OpenVINO+OpenCV 文本检测与识别

OpenVINO + OpenCV实现点头与摇头识别验证

OpenVINO + OpenCV实现车辆检测与道路分割

OpenCV二值图像分析之寻找缺失与靶心

OpenCV 基于Inception模型图像分类

OpenCV4.4 + YOLOv4 真的可以运行了.....

告别对象检测图像数据手动标注的坑,用Anno-Mage半自动图像标注工具

经验 | OpenCV图像旋转的原理与技巧



Halcon缺陷檢測實例轉OpenCV實現(六) 瓶口缺陷檢測

激光雷達+GPS+IMU+輪速計的傳感器融合的定位系統



計算機視覺life

OpenCV與AI深度學習

